RISC-V com DMA e acelerador de multiplicação matricial

Entrega Parcial I — Planejamento, microarquitetura e modelo de referência

1. Objetivo

O projeto calcula C = A × B, com A de dimensão M×K, B de dimensão K×N e C de dimensão M×N. A CPU configura a operação; o DMA busca os dados e grava o resultado; o acelerador realiza as multiplicações e somas. Após o início, a CPU não transfere elementos por software.

Nesta etapa, apresentamos a arquitetura proposta, o mapa de memória, as interfaces e o modelo de referência em Python, conforme solicitado no projeto. O processador existente está em rv32i/. Os demais módulos RTL, o firmware e o UVM integrado serão desenvolvidos nas próximas entregas.

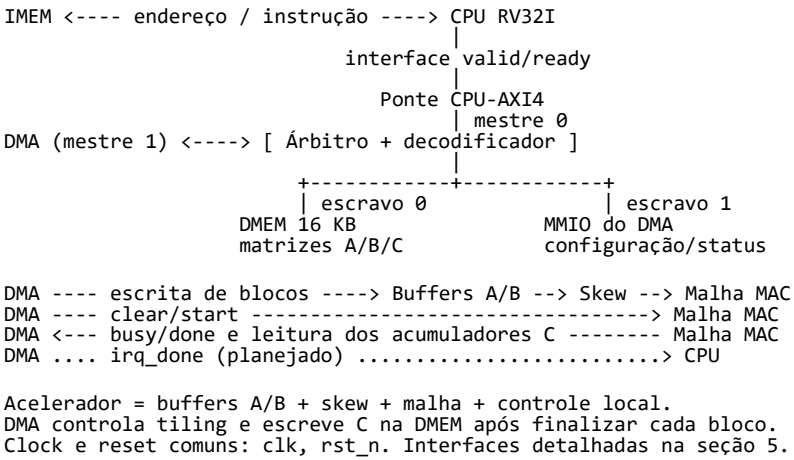
2. Arquitetura proposta

Adotamos arquitetura Harvard, com memória de instruções exclusiva da CPU e memória de dados compartilhada com o DMA. Não haverá cache. O reaproveitamento dos operandos ocorre nos buffers locais e na malha sistólica.

A CPU usa uma ponte para acessar o AXI4. CPU e DMA disputam a interconexão, com prioridade fixa para o DMA, sem interromper transações em andamento. O decodificador encaminha cada acesso à memória de dados ou aos registradores do DMA.

O acelerador contém buffers A/B, lógica de atraso das entradas (skew) e uma malha de unidades MAC. A malha será parametrizada para 2×2, 4×4 e 8×8. O DMA controla o particionamento em blocos (tiling).

Diagrama de blocos



A IMEM já é instanciada dentro de rv32i_core, mas aparece separada para mostrar a organização Harvard. O núcleo não tem pipeline e permite espera nos acessos de dados. A entrada irq_done ainda será adicionada na integração.

3. Dados e funcionamento do acelerador

Decisão	Definição e motivo
Dimensões	1 ≤ M, K, N ≤ 32, incluindo matrizes retangulares e ímpares. Cada matriz ocupa no máximo 4 KB.
Operandos A/B	Inteiros de 8 bits com sinal, de −128 a 127. Reduzem a largura dos multiplicadores e buffers.
Resultado C	Inteiro de 32 bits com sinal, sem saturação. Com K ≤ 32, a magnitude máxima é 32 × 128 × 128 = 524.288, sem overflow.
Armazenamento	Ordem por linhas (row-major), um elemento por palavra de 32 bits. Simplifica o DMA, mas utiliza apenas 8 dos 32 bits em cada transferência de A/B.
Buffers	Um buffer de T×T elementos para A e outro para B, com T = ARRAY_SIZE. C permanece nos acumuladores dos MACs.

Em cada palavra de A/B, o valor ocupa os bits [7:0]; o exportador zera os demais bits.

Por exemplo, −1 é armazenado como 000000FF. C ocupa os 32 bits. O endereço de um elemento é:

```
endereço(i, j) = base + 4 × (i × número_de_colunas + j)
```

Usamos o fluxo output-stationary: cada MAC mantém um acumulador de C, enquanto A avança para a direita e B para baixo. A linha i de A entra com i ciclos de atraso e a coluna j de B com j ciclos. Um produto de dois tiles T×T usa 3T−2 ciclos ideais de cálculo.

Para cada bloco de C, o DMA zera os acumuladores, carrega os blocos correspondentes de A/B e inicia o cálculo. Repete esse processo ao longo de K, preservando as somas parciais. Grava C na memória apenas após terminar a acumulação daquele bloco.

Nas bordas, o DMA preenche localmente com zero as posições fora da matriz e transfere somente os elementos válidos. Assim, a mesma malha atende matrizes maiores, menores ou não múltiplas de T.

4. Mapa de memória

Memórias e regiões

A IMEM possui 256 palavras de 32 bits (1 KB), de 0x00000000 a 0x000003FF, carregadas por arquivo hexadecimal. Seu espaço é separado da memória de dados.

A DMEM planejada possui 16 KB. O mapa abaixo indica a distribuição padrão; as bases das matrizes são configuráveis.

Faixa de endereços	Uso
0x00000000–0x00000FFF	Dados gerais e pilha da CPU
0x00001000–0x00001FFF	Matriz A, base padrão 0x1000
0x00002000–0x00002FFF	Matriz B, base padrão 0x2000
0x00003000–0x00003FFF	Matriz C, base padrão 0x3000
0x40000000–0x4000002F	Registradores do DMA/acelerador

As bases devem ser alinhadas em 4 bytes. As regiões A, B e C não podem se sobrepor e devem caber integralmente na DMEM. O firmware também deve preservar sua pilha e seus dados. Os tamanhos das regiões são 4×M×K, 4×K×N e 4×M×N bytes, respectivamente.

A decodificação verifica os limites completos das faixas, não apenas os bits superiores. Acessos fora delas recebem erro (DECERR), sem acessar memória ou registradores. Toda a rajada deve caber na região selecionada. Por exemplo, 0x00010000 não é um endereço válido da DMEM.

Registradores

Escolhemos oito registradores de configuração e controle. Também incluímos três contadores para a comparação de desempenho e um identificador do tamanho da malha. Todos têm 32 bits; os endereços abaixo indicam o primeiro byte de cada palavra.

Offset	Endereço Absoluto	Nome do Registrador	Acesso	Valor Reset	Descrição dos Campos e Bits
0x00	0x4000_0000	DMA_CTRL	R/W	0x0000_0000	bit[0] (START): Escrever 1 dispara a operação autônoma do DMA (auto-limpante). bit[1] (IRQ_EN): 1 habilita geração do sinal de interrupção irq_done ao concluir. bit[2] (SOFT_RST): 1 reinicia contadores e flags de status.
0x04	0x4000_0004	DMA_STATUS	R / W1C	0x0000_0000	bit[0] (BUSY): 1 enquanto o DMA ou o Systolic Array estão em execução. bit[1] (DONE): 1 quando toda a matriz C foi gravada na DMEM (limpo ao escrever 1 ou em novo START). bit[2] (ERR): 1 se a configuração violar dimensões, alinhamento, capacidade da DMEM ou não sobreposição (seções 3 e 4).
0x08	0x4000_0008	DMA_ADDR_A	R/W	0x0000_1000	Endereço-base da Matriz A na DMEM (alinhado em 4 bytes).
0x0C	0x4000_000C	DMA_ADDR_B	R/W	0x0000_2000	Endereço-base da Matriz B na DMEM (alinhado em 4 bytes).
0x10	0x4000_0010	DMA_ADDR_C	R/W	0x0000_3000	Endereço-base da Matriz C na DMEM (alinhado em 4 bytes).
0x14	0x4000_0014	DMA_DIM_M	R/W	0x0000_0004	Número de linhas da Matriz A e da Matriz C (1 ≤ M ≤ 32).
0x18	0x4000_0018	DMA_DIM_K	R/W	0x0000_0004	Número de colunas de A e linhas de B (1 ≤ K ≤ 32).
0x1C	0x4000_001C	DMA_DIM_N	R/W	0x0000_0004	Número de colunas da Matriz B e da Matriz C (1 ≤ N ≤ 32).
0x20	0x4000_0020	PERF_TOTAL_CYCLES	RO	0x0000_0000	Ciclos totais entre START e DONE (DMA + Malha).
0x24	0x4000_0024	PERF_COMP_CYCLES	RO	0x0000_0000	Ciclos com a malha ativa (acc_busy = 1).
0x28	0x4000_0028	PERF_MEM_READS	RO	0x0000_0000	Palavras lidas da DMEM pelo DMA.
0x2C	0x4000_002C	HW_ARRAY_SIZE	RO	ARRAY_SIZE	Retorna o parâmetro físico ARRAY_SIZE sintetizado (2, 4 ou 8).

Uma configuração inválida apresentada quando o DMA está ocioso não inicia transferências: dimensões fora de 1 a 32, desalinhamento, sobreposição ou regiões fora da DMEM resultam em ERR=1 e BUSY=0.

5. Interfaces

Todos os módulos usam o mesmo clk, com transferências na borda de subida, e reset rst_n ativo em zero.

CPU e ponte AXI4

O núcleo existente está em rv32i/rv32i_core.v (rv32i/rv32i_core.v). Sua interface de dados já possui espera por valid/ready; a ponte AXI4 será implementada posteriormente.

Sinal	Direção (ref. CPU)	Largura	Descrição Funcional
clk	Entrada	1 bit	Relógio principal do sistema (borda de subida ativa).
rst_n	Entrada	1 bit	Reset global assíncrono, ativo em nível baixo (0).
dmem_valid	Saída	1 bit	Indica que a CPU está solicitando uma leitura (LW/LH/LB) ou escrita (SW/SH/SB).
dmem_ready	Entrada	1 bit	Indica resposta disponível para concluir a solicitação da CPU; dados/erro válidos nessa mesma borda. A ponte deve ter recebido a resposta AXI4 correspondente.
dmem_write	Saída	1 bit	1 = Operação de escrita (Store); 0 = Operação de leitura (Load).
dmem_addr	Saída	32 bits	Endereço alinhado em palavra ({alu_result[31:2], 2'b00}).
dmem_wdata	Saída	32 bits	Dado de escrita posicionado nos bytes correspondentes pela load_store_unit.
dmem_wstrb	Saída	4 bits	Máscara de habilitação de bytes na escrita (4'b1111=SW, 4'b0011/1100=SH, 1 bit=SB).
dmem_rdata	Entrada	32 bits	Palavra de 32 bits lida da DMEM ou de um registrador MMIO.
dmem_error	Entrada	1 bit	Indica erro de barramento (BRESP/RRESP != OKAY).
irq_done	Entrada	1 bit	Conexão futura DMA → CPU, fora da ponte. Ainda não existe no núcleo atual; mecanismo de atendimento será definido na integração.

A requisição termina na borda com dmem_valid && dmem_ready. Durante a espera, a CPU mantém a instrução, o endereço, a direção, os dados e a máscara. A ponte atende uma solicitação por vez e não deve repetir uma escrita. Dados de leitura e erro devem corresponder à solicitação concluída; fora da resposta, dmem_error=0. A conexão irq_done é direta entre DMA e CPU, não passa pela ponte.

Barramento AXI4

CPU e DMA são mestres; DMEM e registradores MMIO são escravos. A CPU usa uma palavra por transação (LEN=0); o DMA usa rajadas INCR de palavras de 4 bytes. Prevemos uma transação em andamento por vez, sem reordenação. IDs fixos e atributos constantes serão detalhados nas portas RTL.

Canal AXI4	Sinal	Largura	Origem → Destino	Descrição no Sistema
AW (Write Address)	awaddr	32 bits	Master → Slave	Endereço inicial da escrita (simples ou burst).
	awlen	8 bits	Master → Slave	Comprimento da rajada: Beats = awlen + 1 (0 na CPU; L-1 no DMA, com L palavras válidas na rajada).
	awsize	3 bits	Master → Slave	Tamanho de cada transferência: 3'b010 (4 bytes = 32 bits).

Canal AXI4	Sinal	Largura	Origem → Destino	Descrição no Sistema
	awburst	2 bits	Master → Slave	Tipo de rajada: 2'b01 (INCR — incrementa endereço em +4 a cada beat).
	awvalid / awready	1 bit	Handshake	Handshake de aceitação do endereço de escrita.
W (Write Data)	wdata	32 bits	Master → Slave	Palavra de 32 bits a ser escrita na DMEM ou registrador MMIO.
	wstrb	4 bits	Master → Slave	Máscara de bytes ativos (4'b1111 nas escritas de 32 bits do DMA).
	wlast	1 bit	Master → Slave	1 no último dado da rajada de escrita.
	wvalid / wready	1 bit	Handshake	Handshake de transferência de cada palavra de escrita.
B (Write Resp)	bresp	2 bits	Slave → Master	Status da escrita (2'b00 = OKAY, 2'b10 = SLVERR).
	bvalid / bready	1 bit	Handshake	Handshake de confirmação de término da escrita.
AR (Read Address)	araddr	32 bits	Master → Slave	Endereço inicial da leitura (simples ou burst).
	arlen	8 bits	Master → Slave	Comprimento da rajada: Beats = arlen + 1 (0 na CPU; L-1 no DMA, com L palavras válidas na rajada).
	arsize	3 bits	Master → Slave	Tamanho de cada leitura: 3'b010 (4 bytes = 32 bits).
	arburst	2 bits	Master → Slave	Tipo de rajada: 2'b01 (INCR).
	arvalid / arready	1 bit	Handshake	Handshake de aceitação do endereço de leitura.
R (Read Data)	rdata	32 bits	Slave → Master	Palavra de 32 bits lida da DMEM ou MMIO.
	rresp	2 bits	Slave → Master	Status da leitura (2'b00 = OKAY).
	rlast	1 bit	Slave → Master	1 na última palavra da rajada de leitura.
	rvalid / rready	1 bit	Handshake	Handshake de entrega de cada palavra lida.

Cada canal transfere quando VALID e READY estão altos na mesma borda. O emissor mantém VALID e conteúdo estáveis durante a espera, sem depender de READY para apresentar VALID. Endereço e dados de escrita têm canais independentes. A escrita termina na resposta B; a leitura, na aceitação do último dado R.

O DMA recebe prioridade quando ambos os mestres solicitam acesso. Uma transação iniciada termina antes da troca de mestre. Durante o cálculo na malha, o DMA libera o barramento; a CPU pode acessá-lo, sujeita à resposta do escravo.

Cada rajada transfere um trecho válido de uma linha do tile, com LEN=L−1. Trechos nas bordas são encurtados, e a rajada também é dividida se alcançar uma fronteira de 4 KB. Não há transferências para os zeros de padding. O acesso MMIO usa palavras alinhadas, uma por transação.

Referência do protocolo: AMBA AXI/ACE, Arm, capítulos A3.2–A3.4 (https://community.arm.com/cfs-file/__key/communityserver-discussions-components-files/476/IHI0022H_5F00_amba_5F00_axi_5F00_protocol_5F00_spec.pdf).

DMA e acelerador

O DMA carrega os buffers e controla cada cálculo pelos sinais abaixo. IDX_W = clog2(ARRAY_SIZE).

Sinal	Direção (DMA → Acc)	Largura	Descrição Funcional
acc_clear	DMA → Acelerador	1 bit	Pulso de 1 ciclo que zera todos os acumuladores acc[i][j] da malha (acionado quando tk = 0).
acc_start	DMA → Acelerador	1 bit	Pulso de 1 ciclo que inicia o processamento sistólico do bloco carregado nos buffers locais.
acc_busy	Acelerador → DMA	1 bit	Permanece em 1 durante os 3T - 2 ciclos enquanto os dados atravessam a malha com skew.
acc_done	Acelerador → DMA	1 bit	Pulso de 1 ciclo indicando que o bloco atual terminou de ser acumulado nos PEs.
buf_a_we	DMA → Acelerador	1 bit	Habilita escrita de um elemento no Buffer Local A.
buf_a_row	DMA → Acelerador	IDX_W	Índice de linha (0 … T-1) no Buffer Local A.
buf_a_col	DMA → Acelerador	IDX_W	Índice de coluna (0 … T-1) no Buffer Local A.
buf_a_wdata	DMA → Acelerador	8 bits	Elemento signed [7:0] (int8) escrito no Buffer Local A (ou 0 em caso de zero-padding).
buf_b_we	DMA → Acelerador	1 bit	Habilita escrita de um elemento no Buffer Local B.
buf_b_row	DMA → Acelerador	IDX_W	Índice de linha (0 … T-1) no Buffer Local B.
buf_b_col	DMA → Acelerador	IDX_W	Índice de coluna (0 … T-1) no Buffer Local B.
buf_b_wdata	DMA → Acelerador	8 bits	Elemento signed [7:0] (int8) escrito no Buffer Local B (ou 0 em caso de zero-padding).
buf_c_row	DMA → Acelerador	IDX_W	Seleciona a linha (0 … T-1) do acumulador da malha para leitura pelo DMA.
buf_c_col	DMA → Acelerador	IDX_W	Seleciona a coluna (0 … T-1) do acumulador da malha para leitura pelo DMA.
buf_c_rdata	Acelerador → DMA	32 bits	Valor acumulado signed [31:0] (int32) do elemento PE(row, col).

Com acc_busy=0, cada buf_a_we/buf_b_we grava um elemento na borda de subida. Não há ready nessas portas: cada buffer aceita uma escrita por ciclo enquanto o acelerador está ocioso. Todos os elementos do tile, incluindo zeros de padding, são carregados antes de iniciar.

acc_clear zera os acumuladores antes do primeiro produto de um bloco de C. É um pulso separado de acc_start. Nos produtos seguintes ao longo de K, os acumuladores são preservados.

O acelerador aceita acc_start quando ocioso; busy sobe e a primeira atualização MAC ocorre na borda seguinte. Após 3T−2 atualizações, busy cai e done fica alto por um ciclo. A leitura de C é combinacional, selecionada por linha/coluna: após done, o DMA mantém os índices durante o ciclo e captura o valor na próxima borda. O resultado permanece até novo clear ou cálculo.

No reset, busy/done e acumuladores são zerados. Os buffers serão preenchidos pelo DMA antes do uso. O tratamento de comandos durante busy e o atendimento da interrupção serão detalhados antes da implementação desses módulos.

6. Modelo de referência

O código está em sw/golden_model/ (sw/golden_model/README.md). Mantivemos duas formas de cálculo:

- matmul_reference_alg: multiplicação direta, usada como resultado esperado.

- matmul_tiled_golden: cálculo por blocos, com simulação da malha e zero-padding.

O modelo valida dimensões e valores int8. O validador validate_memory_layout verifica separadamente alinhamento, limites e sobreposição das regiões. A exportação gera arquivos .hex em ordem por linhas para os testes futuros do RTL.

Na raiz do projeto, execute:

```
python -B sw/golden_model/test_golden_model.py
python -B sw/golden_model/golden_model.py -m 8 -k 8 -n 8
```

Para gerar vetores explicitamente:

```
python -B sw/golden_model/golden_model.py -m 8 -k 8 -n 8 --export-dir sw/golden_model/test_vectors
```

Os 11 grupos de testes verificam skew, operandos extremos, tiling, bordas, conteúdo dos HEX, respostas fixas, entradas inválidas, overflow unitário, métricas, limites do projeto e endereçamento. A execução da suíte resultou em 11/11 PASS. Os testes de exportação usam arquivos temporários.

Para duas matrizes 8×8, o modelo produz:

Malha	Produtos de tiles	Ciclos de cálculo	Palavras lidas de A/B	Comparação de C
2×2	64	256	512	PASS
4×4	8	80	256	PASS
8×8	1	22	128	PASS

Esses ciclos representam apenas a malha ideal. Não incluem carga, controle do DMA, arbitragem ou espera na memória. Área, frequência e latência total serão medidas no RTL e na síntese.

7. Organização e próximos passos

Diretório	Conteúdo atual ou previsto
rv32i/	CPU existente, programas e testes
sw/golden_model/	Modelo Python, testes, documentação e vetores
docs/	Especificação em Word e PDF
rtl/	Pastas reservadas: cpu, bus, dma, accelerator, memory e top
sw/firmware/	Reservada para o programa de configuração
tb/	Reservada para testes unitários e UVM integrado
syn/	Reservada para scripts e relatórios de síntese

A próxima entrega trata do RTL do acelerador e de seus testes unitários.

O **README** é a especificação principal.